

基于 ResNet50 的水稻病虫害识别

丁士宁

(信阳农林学院 信息工程学院, 河南 信阳 464000)

摘要: 为了准确识别水稻病虫害, 收集 8 种水稻病虫害图像和健康水稻图像, 构建水稻病虫害数据集。将残差网络 ResNet50 用于水稻病虫害识别, 在原模型基础上引入了迁移学习和 NonLocal 注意力机制。实验结果表明, 改进模型的准确率、精确率、召回率、F1-score 分别达到 99.12%、99.31%、99.27%、99.28%, 相比于原模型分别提升了 2.92%、2.91%、4.05%、3.60%。与模型 DenseNet121、Inception V3、ShuffleNet V2、MobileVit-small、ResNext50 相比, 改进模型的准确率、精确率、召回率、F1-score 至少高出 2%。实验验证了所提模型的有效性, 该模型可以准确识别这几种水稻病虫害。

关键词: 水稻病虫害; ResNet50 模型; 迁移学习; NonLocal 注意力机制

中图分类号: TP391.41; TP18

文献标识码: A

文章编号: 2096-4706 (2024) 16-0127-05

Identification of Rice Pests and Diseases Based on ResNet50

DING Shining

(School of Information Engineering, Xinyang Agriculture and Forestry University, Xinyang 464000, China)

Abstract: In order to accurately identify rice pests and diseases, 8 types of rice pests and diseases images and health rice images are collected, which are used to construct a rice pests and diseases dataset. The Residual Network ResNet50 is used for identification of rice pests and diseases, and Transfer Learning and NonLocal Attention Mechanisms are introduced on the basis of the original model. The experimental results show that the accuracy, precision, recall, and F1-score of the improved model have reached 99.12%, 99.31%, 99.27%, and 99.28%, respectively, which are 2.92%, 2.91%, 4.05%, and 3.60% higher than the original model. Compared with models DenseNet121, Inception V3, ShuffleNet V2, MobileVit-small and ResNext50, the improved model has at least 2 percentage points higher on accuracy, precision, recall, and F1-score. The experiment verifies the effectiveness of the proposed model, which can accurately identify these types of rice pests and diseases.

Keywords: rice pests and diseases; ResNet50 model; Transfer Learning; NonLocal Attention Mechanism

0 引言

水稻作为我国主要的粮食作物, 病虫害侵害对于水稻生长产生较大影响, 不定期检测水稻病虫害, 可以及时采取针对性的防治措施, 有利于保障水稻的产量和质量^[1]。

传统的水稻病虫害识别方法有赖于农民的丰富经验, 识别效率低下; 传统的机器学习方法又受限于人工特征提取^[1]。而深度学习的代表性算法之一的卷积神经网络 (Convolutional Neural Network, CNN) 具有端到端的学习机制, 为水稻病虫害检测提供了新的思路。目前已有许多基于深度卷积网络的植物病虫害识别的研究。黄双萍等使用 GoogLeNet 模型对水稻穗温病进行检测, 准确率高达 92.0%^[2]。范春全等

运用 ResNet50 预训练网络构建面向 16 种水稻病虫害的识别模型, 模型使用了二分类数据过滤模型, 最终 top-1 准确率达 95.23%^[3]。梁万杰等使用自行设计的 10 层卷积神经网络对水稻二化螟虫害进行识别, 对应的模型交叉验证精度达 89.14%^[4]。代国威等构建融合 ResNet 和支持向量机的模型, 将其用于葡萄园冠层图像叶片覆盖度分类^[5]。姜红花等从注意力机制、特征图裁剪等方面改进 ResNet18 模型, 对苹果 5 类叶片病害的识别准确率高达 98.25%, 优于原模型 ResNet18 和 VGG^[6]。陈浪浪等以 DenseNet121 为基础网络, 引入迁移学习和坐标注意力机制后, 在水稻病虫害数据集上的识别准确率达到 98.95%^[7]。江顺等在 AlexNet 模型的基础上, 采用缩小卷积核、增加卷积层深度、引入 RReLU 激活函数等方法改进模型, 改进模型对水稻害虫识别的准确率达到 96.17%^[8]。李聪等将感兴趣区域提取方法和迁移学习技术引入 ResNeXt 模型, 提出了 TL-ROI-X-ResNext-50 分类模型, 实现了干制哈密大枣果梗/花萼及缺陷识别, 识别准确率达

收稿日期: 2024-02-20

基金项目: 信阳农林学院青年教师

科研基金项目: 基于深度学习的水稻叶片病害预防检测研究 (QN2021057)

94.17%^[9]。陈晓等提出了基于改进 MobileViT 网络的番茄病害识别模型，识别准确率达到 99.16%^[10]。胡骏等针对水稻稻瘟病识别，提出了 VGG16 的改进模型 VGG16-H，改进模型的识别准确率达 98.7%，比原模型 VGG16 提高 1.6%^[11]。

本文将模型 ResNet50 应用于水稻病虫害识别。首先收集 8 种水稻病虫害图像和健康水稻图像，构建水稻病虫害数据集；然后在 ResNet50 的基础上引入了迁移学习和注意力机制；最后通过实验验证模型的有效性。

1 材料与模型

1.1 数据来源

所用数据都是开源数据，来源于文献 [12]。该数据集包含 1 426 张图像，其中包含 5 类水稻病害、3 类水稻虫害以及健康水稻图像，共计 9 个类别。该数据集的图像是由孟加拉国水稻研究所 (Bangladesh Rice Research Institute, BRRI) 收集的，是真实环境中不同背景、不同天气条件下收集而来的。部分数据集图像如图 1 所示。




图 1 水稻病虫害图片示例

按照 4:1 的比例将数据集划分为训练集和测试集，训练集包含 1 143 张图像，测试集包含 283 张图像，水稻各类病虫害图像的数量如表 1 所示。该数据集图像数量偏少，为了避免过拟合，提升模型训练效果，

采用图像翻转、图像旋转、添加噪声、高斯模糊等方法对图像进行增强，将图像数量扩增为原来的 8 倍。

表 1 水稻各类病虫害图像的数量分布

病害类型	图像数量 / 张	训练集图像数量 / 张	测试集图像数量 / 张
假黑粉病	93	75	18
褐飞虱	71	57	14
白叶枯病	138	110	28
穗颈瘟病	286	229	57
稻螟虫	201	161	40
胡麻斑病	73	58	15
纹枯病	219	176	43
蚜茧蜂	111	89	22
健康株	234	188	46
总计	1 426	1 143	283

1.2 水稻病虫害识别模型

1.2.1 ResNet 模型

在残差神经网络出现之前，深度卷积神经网络面临退化问题。随着网络深度的增加，准确率达到饱和随后迅速下降，而残差学习解决了退化问题，有助于搭建层级更深、识别效果更好的神经网络模型^[13]。

本文选择残差网络 ResNet50 作为基础模型。ResNet50 的模型结构如图 2 所示。模型的输入图像是维度 (224, 224) 的三通道 RGB 图像，模型由卷积层、最大池化层 (Max Pool)、4 类残差块 (Residual Block)、全局平均池化层 (Average Pool)、全连接层 (Fully Connect, FC) 等构成，其核心模块是残差块。残差块由 2 个 1×1 卷积层和 1 个 3×3 卷积层构成，4 类残差块的基本结构相同，不同之处在于卷积层的通道数不同。对于水稻病虫害数据集，全连接层的输出类别数为 9。

1.2.2 迁移学习

深度卷积神经网络的训练需要大量标注好的数据，需要大量数据同时也意味着需要大量的运算资源，但在水稻病虫害识别领域收集大量数据并进行标注是一件耗时又耗资的事情^[7]。因此，在水稻病虫害识别领域引入迁移学习训练模型。将公开数据集 ImageNet 上的预训练模型作为初始模型，该预训练模型由框架 mmpretrain 提供；将在 ImageNet 上学习到的知识推广到水稻数据集，在知识推广的过程中，冻结模型低层特征，对于 ResNet50 模型，冻结前 3 个残差层及以前网络层的参数，微调第 4 个残差层及之后网络层的参数，最终获得训练好的模型。引入的迁移学习显著减少了构建深度卷积神经网络对图像数据量和计算资源的需求，同时还具有加快模型收敛、避免模型过拟合的作用。




图 2 ResNet50 模型结构

1.2.3 注意力机制

水稻图像是在实际环境下采集的,背景复杂。在模型中引入注意力机制,可选择性地关注重要的、感兴趣的信息,减少关注甚至忽视关联不大的信息,进而提升模型的识别效果。在模型 ResNet50 的第四类残差块中引入 NonLocal2d 注意力机制,如图 3 所示。




图 3 引入 NonLocal2d 的残差块

非局部操作的通用计算式表示为:

$$y_i = \frac{1}{C(x)} \sum_{\forall j} f(x_i, x_j) \cdot g(x_j) \quad (1)$$

其中, x 为输入信号, y 为与 x 维度相同的输出信号, i 为输出位置, 如空间、时间或时空的索引, j 为输入特征中所有位置的索引, f 函数计算 x_i 和 x_j 的相似度, g 为函数计算输入信号在 j 的位置, 最终的输出 y 通过相应因子 $C(x)$ 进行标准化处理以后得到^[14-15]。

将式 (1) 对应的非局部操作封装到一个非局部块 (Non-Local block) 中, 定义为:

$$z_i = W_z y_i + x_i \quad (2)$$

其中, W_z 表示权重矩阵, $+x_i$ 表示残差连接^[14-15]。非局部块的结构如图 4 所示。

2 实验结果与分析

2.1 实验环境和参数设置

本文中, 所有模型均在相同环境下运行: 采用 Ubuntu 20.04 操作系统、Python 3.7 开发语言、PyTorch 1.10 框架, 显卡采用 RTX A4000, GPU 加速

库采用 CUDA 11.3 和 CUDNN 8.2。所有模型均借助深度学习开源框架 mmpretrain 1.1 运行。




图 4 非局部块结构

对于本文的 ResNet50 模型, 采用随机梯度下降算法 (Stochastic Gradient Descent, SGD) 更新模型参数, 初始学习率设为 0.001, momentum 设为 0.9, batch size 设为 32, epoch 数设为 100。在 30、60、90 个 epoch 之后, 学习率衰减为原先的 0.1。图像输入尺寸为 (224, 224), ResNet50 模型首先在 ImageNet 数据集上训练, 该模型作为训练的初始化模型由框架 mmpretrain 提供。

2.2 评价指标

采用准确率 (Accuracy)、精确率 (Precision)、召回率 (Recall)、F1-score 指标评价水稻识别模型的性能。这些指标的计算公式如下:

$$\text{Accuracy} = \frac{TP+TN}{TP+FP+FN+TN} \quad (3)$$

$$\text{Precision} = \frac{TP}{TP+FP} \quad (4)$$

$$\text{Recall} = \frac{TP}{TP+FN} \quad (5)$$

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (6)$$

其中, TP (True Positive) 表示将正类划分为正类的样本数量, FP (False Positive) 表示将负类划分为正类的样本数量, FN (False Negative) 表示将正类划分为负类的样本数量, TN (True Negative) 表示将负类划分为负类的样本数量。

2.3 实验结果

为了说明迁移学习和注意力机制对模型结果的影响, 将迁移学习和 NonLocal2d 模块依次加入 ResNet50 模型, 结果如表 2 所示。原模型 ResNet50 的分类准确率、精确率、召回率、F1-score 分别达 96.20%、96.40%、95.22%、95.68%, 引入迁移学习后, 准确率、精确率、召回率、F1-score 分别提升了 2.39%、2.38%、3.65%、3.14%, 继续引入 NonLocal2d 注意力机制后, 准确率、精确率、召回率、F1-score 分别提升了 0.53%、0.53%、0.40%、0.46%。迁移学习和注意力机制的引入, 有效提升了模型对水稻病虫害的识别精度。

表 2 迁移学习和注意力机制对模型的影响 单位: %

模型	准确率	精确率	召回率	F1-score
ResNe50	96.20	96.40	95.22	95.68
ResNe50+ 迁移学习	98.59	98.78	98.87	98.82
ResNe50+ 迁移学习 +NonLocal2d	99.12	99.31	99.27	99.28

为了验证模型的有效性, 将模型与 DenseNet121、Inception V3、ShuffleNet V2、MobileVit-small、ResNext50 进行对比^[16-20]。对比结果展示在表 3 中。本文模型与 DenseNet121、Inception V3、ShuffleNet V2、MobileVit-small、ResNext50 相比, 准确率分别提升了 2.26%、2.87%、1.81%、2.39%、3.14%, 精确率分别提升了 2.11%、2.78%、2.03%、2.93%、3.01%, 召回率分别提升了 3.14%、3.57%、2.57%、2.80%、3.76%, F1-score 分别提升了 2.69%、3.26%、2.38%、2.92%、3.46%。对比结果表明, 改进模型的水稻病虫害识别精度最高。

表 3 不同模型识别结果对比 单位: %

模型	准确率	精确率	召回率	F1-score
DenseNet121	96.86	97.20	96.13	96.59
Inception V3	96.25	96.53	95.70	96.02
ShuffleNet V2	97.31	97.28	96.70	96.90
MobileVit-small	96.73	96.38	96.47	96.36
ResNext50	95.98	96.30	95.51	95.82
本文模型	99.12	99.31	99.27	99.28

3 结 论

收集 8 种水稻病虫害图像和健康水稻图像数据, 构建水稻病虫害图像数据集。将残差网络 ResNet50 用于水稻病虫害识别, 并引入迁移学习和注意力机制。

改进后模型的准确率达 99.12%, 精确率达 99.31%, 召回率达 99.27%, F1-score 达 99.28%, 相比原模型分别提升了 2.92%、2.91%、4.05%、3.60%。与 DenseNet121、Inception V3、ShuffleNet V2 等模型相比, 本文模型对水稻病虫害的识别精度最高。但也存在所收集的水稻病虫害图像数据偏少的问题, 下一步将收集更多的水稻病虫害图像, 扩充数据集的图像数量。

参考文献:

[1] 王菁. 基于改进卷积神经网络的水稻叶片病虫害识别方法研究 [D]. 哈尔滨: 东北农业大学, 2022.

[2] 黄双萍, 孙超, 齐龙, 等. 基于深度卷积神经网络的水稻穗瘟病检测方法 [J]. 农业工程学报, 2017, 33 (20): 169-176.

[3] 范春全, 何彬彬. 基于迁移学习的水稻病虫害识别 [J]. 中国农业信息, 2020, 32 (2): 36-44.

[4] 梁万杰, 曹宏鑫. 基于卷积神经网络的水稻虫害识别 [J]. 江苏农业科学, 2017, 45 (20): 241-243+253.

[5] 代国威, 陈稼瑜, 樊景超. 融合 ResNet 与支持向量机的葡萄园冠层图像叶片覆盖度分类 [J]. 江苏农业学报, 2023, 39 (8): 1713-1721.

[6] 姜红花, 杨祥海, 丁睿柔, 等. 基于改进 ResNet18 的苹果叶部病害多分类算法研究 [J]. 农业机械学报, 2023, 54 (4): 295-303.

[7] 陈浪浪, 张艳. 基于改进深度卷积神经网络的水稻病虫害识别 [J]. 山东农业科学, 2023, 55 (5): 164-172.

[8] 江顺, 黄红星, 莫里楠, 等. 基于改进 AlexNet 的岭南水稻虫害识别方法研究 [J]. 江苏农业科学, 2023, 51 (23): 187-195.

[9] 李聪, 喻国威, 张原嘉, 等. 基于 ResNeXt 与迁移学习的干制哈密大枣果梗/花萼及缺陷识别 [J]. 食品与机械, 2022, 38 (1): 135-140.

[10] 陈晓, 夏颖. 基于改进 MobileViT 网络的番茄叶片病害识别 [J]. 电子测量技术, 2023, 46 (14): 188-196.

[11] 胡骏, 陆兴华, 林桎菀, 等. 改进的 VGG16 在水稻稻瘟病图像识别中的应用 [J]. 计算机应用, 2023, 43 (S2): 196-200.

[12] RAHMAN C R, ARKO P S, ALI M E, et al. Identification and Recognition of Rice Diseases and Pests Using Convolutional Neural Networks [J]. Biosystems Engineering, 2020, 194: 112-120.

[13] HE K M, ZHANG X Y, REN S Q, et al. Deep Residual Learning for Image Recognition [C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 770-778.

[14] WANG X L, GIRSHICK R, GUPTA A, et al. Non-local Neural Networks [C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City: IEEE, 2016: 770-778.

[15] 黄文明, 阳沐利, 蓝如师, 等. 融合非局部神经网络的行为检测模型 [J]. 图学学报, 2021, 42 (3): 439-445.

(下转 135 页)



图 9 第一人称漫游示意图

3.4 模型测量

模型测量帮助用户直观获取模型表面参数,包括长度测量、宽度测量、高度测量、面积测量和角度测量,为用户提供业务需求支撑,如图 10 所示。



图 10 模型测量示意图

4 结 论

随着 BIM+GIS 的快速发展,Three.js+BIM 三维可视化技术在电力行业有着广泛的应用。本文论述了 Three.js+BIM 可视化技术在空气压缩储能电站项目中的应用,空气压缩储能电站可视化平台实现了对变电站建设中产生的变电站模型、数字模型、模型编码以及模型节点等数据成果的统一管理,直观展示了三维

模型不同施工阶段的三维场景。本平台的研发对促进电力行业的智慧电力建设、电力数字化建设和电力一体化建设有着十分重要的意义。

参考文献:

- [1] 弓国军,符国晖,周亚敏.基于 BIM 技术的变电站三维可视化建模研究[J].电子制作,2022,30(2):66-68.
- [2] 胡夏恺,陈俊涛,杨聃,等.基于 Revit 二次开发的 BIM+WebGIS 融合应用研究[J].中南大学学报:自然科学版,2021,52(11):3930-3942.
- [3] 胡夏恺,杨聃,朱悦林,等.基于 BIM+WebGIS 的输电系统结构安全监测可视化平台构建[J].中国农村水利水电,2020(12):185-188+192.
- [4] 陶松梅,张炜.基于 CIM 模型的变电站三维可视化交互技术应用[J].广西电力,2014,37(6):22-24+37.
- [5] 陶银正.基于三维全景的电网数字化建设研究与应用思路构建[J].安徽电气工程职业技术学院学报,2021,26(4):82-86.
- [6] 初建祥,张彦彪,罗金龙,等.3D 打印 BIM 模型在变电站三维可视化设计中的应用[J].电力勘测设计,2022(10):1-6+76.
- [7] 陈雪婷,王泽宇,寇柏源,等.基于 BIM 的建筑模型三维可视化运维管理平台[J].绿色建造与智能建筑,2023(4):33-36+40.
- [8] 周造成.Web3D 可视化技术的研究与应用[J].智慧中国,2022(1):78-79.
- [9] 易立华.基于 Cesium 的 WebGIS 与 BIM 集成研究[D].西安:长安大学,2023.
- [10] 王芳,尤一铭,余婷立.WebGIS 三维可视化平台在电网数字化移交中的应用研究[J].现代信息科技,2021,5(17):7-11.

作者简介: 孙秀巧(1990—),女,汉族,河北沧州人,工程师,硕士研究生,研究方向:地理信息系统;许玉凤(1994—),女,汉族,河南周口人,工程师,硕士研究生,研究方向:地理信息系统和空间信息应用。

(上接 130 页)

[16] HUANG G, LIU Z, MAATEN L V D, et al. Densely Connected Convolutional Networks [C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu: IEEE, 2017: 2261-2269.

[17] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the Inception Architecture for Computer Vision [C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 2818-2826.

[18] MA N N, ZHANG X Y, ZHENG H T, et al. ShuffleNet V2: Practical Guidelines for Efficient CNN Architecture Design [C]//Proceedings of the 15th European Conference on

Computer Vision (ECCV). Berlin: Springer, 2018: 116-131.

[19] MEHTA S, RASTEGARI M. MobileViT: Light-Weight, General-Purpose, and Mobile-Friendly Vision Transformer [J/OL].arXiv:2110.02178v2 [cs.CV].[2024-01-06].https://arxiv.org/abs/2110.02178.

[20] XIE S N, GIRSHICK R, DOLLÁR P, et al. Aggregated Residual Transformations for Deep Neural Networks [C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu: IEEE, 2017: 5987-5995.

作者简介: 丁士宁(1993.06—),男,汉族,河南信阳人,助教,硕士,主要研究方向:模式识别与人工智能。