

基于改进残差网络的水稻病虫害识别检测算法

周 雷¹, 王世平¹, 冯思宇², 徐久升¹, 李 宁¹

(1. 鞍钢资源有限公司鞍山综合服务分公司, 辽宁 鞍山 114000; 2. 沈阳工业大学, 辽宁 沈阳 110870)

摘 要:【目的】解决传统水稻病虫害检测领域面临的人力和时间成本高、误检率高等问题。【方法】文章提出了一种基于改进残差网络的水稻病虫害识别方法, 利用自然环境下的水稻叶片病虫害数据集进行实验, 构建了ResNet34基准模型进行训练, 引入残差连接的神经网络结构, 通过跨层传递信息解决了深度网络训练中的困难。【结果】1) 模型在训练集上的准确率达到0.98, 测试集的准确率、精确率、召回率、精确率和召回率的调和平均数均达到并收敛于0.97。2) 各类病害的检测准确率均在97%以上, 褐斑病的检测准确率达到99.113%, 是4种病害检测中最高的。【结论】改进后的模型在查准率、查全率和召回率方面取得了较好的平衡, 具有较好的泛化能力和实用价值, 能够有效解决水稻病害图像特征不明显、识别效果差等诸多问题。

关键词: 图像处理; 机器学习; 水稻病虫害识别; 残差网络

中图分类号: TP391.4

文献标志码: A

DOI: 10.3969/j.issn.1672-3872.2024.20.008

0 引言

农作物病虫害是农业生产中严重威胁粮食安全的问题之一^[1-2]。因此, 农作物病虫害检测成为保障粮食安全的重要途径之一。及时准确地识别病虫害有助于采取适当的预防和保护措施, 从而提高农产品的产量和质量。然而, 传统的检测方法需要经过培训, 对检测人员的专业素质要求较高, 浪费大量的时间和资源。此外, 由于检测人员的主观判断, 误检的可能性较大。随着人工智能技术的迅速发展, 深度学习技术已经应用到农作物病虫害检测领域, 并取得了一系列的重要成果。

Chen等^[3]提出了一种基于Alex Net模型的Leaf Net模型, 用于检测茶叶病害, 获得了比传统的多层感知机和支持向量机更好的表现。这些研究成果为农作物病虫害检测提供了新的方法和技术, 有助于提高农业生产的效益。傅隆生等^[4]提出了一种基于LeNet的卷积神经网络模型, 用于准确识别多簇猕猴桃果实。研究结果显示, 该模型在识别独立果实方面的准确率较高, 达到了94.78%。这一成果为果实识别技术的发展提供了重要的参考和借鉴, 使人们对于如何利用卷积神经网络模型来识别多簇猕猴桃果实有了更深入的了解, 有望在农业生产和果实质量检测等领域发挥重要作用, 为果实识别技术的研究和应用提供了新的思路和方法。这一研究成果的出现, 也为果实识别领域的研究者们带来了更多的探索空间

和发展机遇。Arnal-Barbedo^[5]利用图像分割技术来提取病虫害的主要特征, 通过卷积神经网络的训练, 提高对病虫害的识别准确率。这项技术可以帮助农民更好地识别和防治病虫害, 从而提高农作物的产量和质量。宋余庆等^[6]采用多层EESP深度学习模型成功实现了对农作物病虫害的精确识别, 准确率达到88.4%。王敬贤^[7]通过迁移学习和多个神经网络模型融合的方法识别玉米和杂草的种类, 准确率达89.9%。刘阳等^[8]利用改进的SqueezeNet模型检测作物叶片病虫害, 准确率达98.13%。王佳^[9]通过提取香芋叶片的颜色和纹理特征建立数据库, 并使用SVM方法进行分类, 准确率达93.00%。项小东等^[10]在Xception模型中结合CEM模块, 提出了一种通道扩张方法(扩张—保持—再扩张—压缩), 在实验中获得了91.90%的准确率。

为了及时准确地识别病虫害, 研究人员不断寻找更好的方法。一种可能的解决方案是引入更细粒度的特征感知能力, 这可以通过改进算法来实现, 例如使用更复杂的神经网络结构或增加网络层数。然而, 这种方法可能会增加模型的参数和复杂度, 导致计算成本的增加。另一种解决方案是通过增加样本数量来改善数据源, 这可以通过采集更多的图像样本来实现, 但这往往是一项费时费力的工作。此外, 标注图像也需要大量的人力资源和时间。因此, 这种方法可能并不是最理想的选择, 需要综合考虑各种因素并找

作者简介: 周雷(1988—), 男, 黑龙江宾县人, 本科, 高级农艺师, 研究方向为盐碱地改良与种植、生态修复、智慧农业。

通信作者: 冯思宇(1998—), 女, 蒙古族, 辽宁葫芦岛人, 硕士研究生, 研究方向为工业工程与管理、信息管理与信息系统。


到一个平衡点来权衡模型的性能和计算成本, 同时也要考虑数据收集和标注的可行性。

基于此, 本文利用 ResNet34 基准模型对水稻病虫害进行识别并不断改进模型, 探索性能和成本的平衡点。ResNet (Residual Neural Network) 是由微软亚洲研究院的何恺明、孙剑等四位华人提出的一种神经网络结构。通过引入 ResNet 单元, 成功训练出了拥有 152 层深度的神经网络, 并在 ILSVRC 2015 比赛中获得冠军。在该比赛中, ResNet 的 top5 错误率仅 3.57%。相比于其他网络结构如 VGGNet, ResNet 的参数量更低, 但效果非常突出。


1 实验材料与方法

1.1 数据集构成


本文采用的数据集包含自然环境下的 4 种水稻叶片病虫害。其中, 白叶枯病 (Bacterial blight) 共 1 584 张, 稻瘟病 (Blast) 共 1 440 张, 褐斑病 (Brown spot) 共 1 600 张, 东格鲁病毒病 (Tungro) 共 1 308 张, 共计 5 932 张, 各类病虫害图片如图 1 所示。



(a) 白叶枯病



(b) 稻瘟病



(c) 褐斑病



(d) 东格鲁病毒病

图 1 各类病虫害示意图

1.2 ResNet 模型的构建

ResNet 是一种在 VGG19 网络的基础上改进得到的网络模型, 残差网络在 VGG19 的基础上引入了残差学习和短路连接, 在一定程度上解决了深层网络训练模型中经常会发生的梯度爆炸或消失造成的性能不足问题。短路连接允许跳过一定的层数, 将输入特征与输出特征直接相加, 以此得到输入和期望输出之间的残差, 并对残差进行优化, 从而实现对网络模型的优化。与传统的 VGG19 不同, 残差网络模型在通过下采样对特征图进行尺寸缩小时直接采用步幅为 2 的卷积操作, 这能够在减少特征图尺寸的同时引入更多的非线性变换, 使网络模型的复杂程度更加优秀, 而 VGG19 则是通过最大池化层来完成这一操作。ResNet34 的整个网络模型包括了 4 个残差块组, 输出通道分别为 64、128、256、512, 特征图的数量会随着尺

寸的不断缩小而翻倍,能够很好地保证特征的有效性。通过这样的操作,残差网络模型能够有效地解决水稻病虫害图像特征不明显、识别效果差等诸多问题。

ResNet的设计采用了残差连接的核心思想,通过引入这种连接方式,可以让信息在网络中跨层传递。这样一来,深度神经网络中的梯度消失和梯度爆炸问题得到了解决,使得网络更易于训练。另外,残差连接还能够帮助ResNet拥有更深更宽的网络结构,而不会导致性能下降。这样一来,网络就能够学习到更多的特征信息,进而提高模型的准确率。此外,残差连接还带来了加速的好处。由于信息可以直接跨层传递,网络在训练过程中能够更快地收敛,从而加快了神经网络的训练速度。ResNet的设计思想具有很好的推广性,这种残差连接的方式不仅可以应用于ResNet本身,还可以直接应用到其他网络结构中,比如InceptionNet。通过引入残差连接,其他网络结构也可以解决深度神经网络中的梯度消失和梯度爆炸问题,优化网络的训练效果。




图2 训练集与测试集

经过50个epoch的训练后,训练集损失函数如图3所示,测试集损失函数如图4所示。训练集损失函数降低到0.13并收敛,同时使测试集损失函数收敛于0.15。这表明训练成功使模型适应了水稻病虫害检测任务。

表1 实验计算机配置

名称	配置
中央处理器(CPU)	11th Gen Intel® Core™ i7-11700 CPU@2.50 GHz
运行内存	64 GB
显卡(GPU)	NVIDIA GeForce RTX 3060
GPU加速库	cuda_11.2.2_461.33_win10 cudnn-11.2-windows-x64-v8.1.0.77
操作系统	Windows 10
数据处理	Python 3.7 numpy pandas
深度学习框架	Pytorch

总之,ResNet的设计极大地加速了神经网络的训练过程,并在模型准确率上取得了显著提升。其核心思想是引入残差连接,允许信息在网络中跨层传递,解决了深度神经网络中的梯度消失和梯度爆炸问题,使得网络更易于训练。这种设计思想具有很好的推广性,可以应用于其他网络结构中。通过跨层传递信息,ResNet能够更好地捕捉到图像中的细节和特征,进而提升模型的性能。它的创新之处在于突破了传统神经网络对于层数的限制,通过增加网络的深度,进一步提升了网络的表达能力。这种创新使得神经网络更深、更复杂,从而在各种视觉任务中取得了突破性的成果。

2 模型训练

通过对水稻病虫害数据进行采集及处理,获得原始数据集共计5 932张,训练集:测试集=4:1,如图2所示。通过LabelMe软件标注后,将训练集数据转换成.json格式,用于模型训练,共计训练50个epoch,实验计算机配置如表1所示。

选用的模型评价指标有:准确率(*Accuracy*),精确率(*Precision*),召回率(*Recall*),精确率和召回率的调和平均数(*F1_score*)。




图3 训练集损失函数




图4 测试集损失函数

1) 准确率 (*Accuracy*) 是衡量模型分类准确性的直观指标, 即正确分类的像素数量占总像素数量的比例。然而, 在类别不平衡的情况下, 准确率可能会产生误导。预测对的样本数除以所有的样本数就是准确率, 它对应语义分割的像素准确率 *PA*, 公式如下:

$$Accuracy = (True\ Positives + True\ Negatives) / (True\ Positives + False\ Positives + True\ Negatives + False\ Negatives) \quad (1)$$

2) 精确率 (*Precision*) 又称查准率, 对应语义分割的类别像素准确率 *CPA*。查准率是评估图像分割模型性能的常用指标之一, 表示预测为正样本的样本中实际为正样本的比例, 即模型预测正确的正样本占所有预测为正样本的比例。其计算公式为:

$$Precision = True\ Positives / (True\ Positives + False\ Positives) \quad (2)$$

3) 召回率 (*Recall*) 又称查全率, 在语义分割常用指标中没有对应关系, 它表示的意义是真实值中某类别被预测正确的概率。

4) *F1_score* 是基于精确率 (*Precision*) 和召回率 (*Recall*) 的调和平均值, 它在类别不平衡的情况下比准确率更具代表性。其计算公式为:

$$F1_score = 2 * (Precision * Recall) / (Precision + Recall) \quad (3)$$

训练集准确率如图5所示, 测试集分类评估指标如图6所示。由图5、图6可知, 模型在训练集上的准确率达到0.98, 同时在测试集上的准确率、精确率、召回率、精确率和召回率的调和平均数也均达到了0.97, 并且这些指标已经收敛。这表明模型在准确率、精确率和召回率方面取得了较好的平衡, 且具有较好的泛化能力和实用价值。

3 实验结果

为了验证本文提出的识别检测模型的准确度并




图5 训练集准确率




图6 测试集分类评估指标

确保其能够满足工程需求, 从现场采集了水稻的图像进行检测。这些图像是在实际田间环境中拍摄获得的, 以确保其具备泛化性的特点, 能够真实反映日常的水稻病虫害情况。采集的图像包含了水稻稻瘟病、白叶枯病、褐斑病以及东格鲁病毒病等常见病害的情况。通过对采集的图像进行处理和分析, 能够判断识别检测模型能否准确地识别出水稻的病虫害类型, 并对其进行有效的分类。这样的验证将为人们提供关于模型性能和可靠性的重要信息, 以便在实际应用中能够更好地进行水稻病虫害的防治工作, 全面评估识别检测模型的准确度和可行性, 为日常水稻病虫害的早期识别和防治提供有效的支持。水稻病虫害检测结果如图7所示。

由图7可知, 各类病害的检测准确率均在97%以上。其中, 褐斑病的检测准确率达到99.113%, 是4种病害检测中最高的。通过利用深度学习技术对水稻病虫害进行有效的检测和识别, 将传统的现场专家操作转变为由计算机进行的图像处理过程。这种转变不仅减少了人力成本, 还大大缩短了水稻病虫害种类测定的时间。由专业工程师辅助建立的样本数据标签集和基于ResNet的网络模型, 能够在一定程度上避免现场环境和人为误差对识别结果的影响。这种方法能够提高识别的准确性, 确保农作物高产, 最大程度地保护水稻作物健康生长。因此, 基于深度学

习的图像检测识别模型的建立不仅提高了水稻病虫害的识别准确性,还为智慧农业的发展和实施提供了重要的支持。通过应用这项技术,人们能够更加高效地预防水稻病虫害,提高农作物的产量和质量。



图7 水稻病虫害检测结果

4 结论

本文提出了一种基于改进的ResNet34模型的水稻病虫害检测算法,用于识别具有不同病害的农作物叶片图像。改进后的模型能够有效地解决水稻病害图像特征不明显、识别效果差等诸多问题,不仅减少

了模型参数和复杂度,而且泛化能力更强。与原有的研究方法相比,提出的改进模型可以在细粒度水平上学习图像特征,从而准确识别各种农作物疾病。未来将进一步对模型进行剪枝,并部署到手机端,建立实时的病虫害检测系统平台。

参考文献:

- [1] 杨孟辑. 基于迁移学习的农作物病虫害预警系统研究[D]. 成都: 成都大学, 2021.
- [2] 全国农业技术推广服务中心. 2022年全国农作物重大病虫害发生趋势预报[N]. 农民日报, 2022-02-16(6).
- [3] CHEN J, LIU Q, GAO L. Visual Tea Leaf Disease Recognition Using a Convolutional Neural Network Model[J]. Symmetry, 2019, 11(3): 343.
- [4] 傅隆生, 冯亚利, Elkamil Tola, 等. 基于卷积神经网络的田间多簇猕猴桃图像识别方法[J]. 农业工程学报, 2018, 34(2): 205-211.
- [5] ARNAL-BARBEDO J G. Plant disease identification from individual lesions and spots using deep learning[J]. Biosystems Engineering, 2019, 180: 96-107.
- [6] 宋余庆, 谢熹, 刘哲, 等. 基于多层EESP深度学习模型的农作物病虫害识别方法[J]. 农业机械学报, 2020, 51(8): 196-202.
- [7] 王敬贤. 基于卷积神经网络和迁移学习的农作物病害和杂草图像识别研究[D]. 合肥: 中国科学技术大学, 2019.
- [8] 刘阳, 高国琴. 采用改进的SqueezeNet模型识别多类叶片病害[J]. 农业工程学报, 2021, 37(2): 187-195.
- [9] 王佳. 计算机视觉在香茅病害检测中的应用研究[J]. 农机化研究, 2020, 42(8): 241-244.
- [10] 项小东, 翟蔚, 黄言志, 等. 基于Xception-CEMs神经网络的植物病害识别[J]. 中国农机化学报, 2021, 42(8): 177-186.

(上接第20页)

- with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6): 1137-1149.
- [6] REDMON J, FARHADI A. YOLOv3: An Incremental Improvement[EB/OL]. (2018-04-08). <https://arxiv.org/pdf/1804.02767>.
 - [7] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single shot multibox detector[C]//LEIBE B, MATAS J, SEBE N, et al. Computer Vision-ECCV 2016, October 11-14, 2016, Amsterdam, The Netherlands. Cham: Springer, 2016: 21-37.
 - [8] 拉毛杰, 安见才让. 基于卷积神经网络的畜牧业动物图像识别研究[J]. 软件, 2020, 41(8): 43-45.
 - [9] 黄丽明, 王懿祥, 徐琪, 等. 采用YOLO算法和无人机影像的松材线虫病异常变色木识别[J]. 农业工程学报, 2021, 37

(14): 197-203.

- [10] 鲍文霞, 谢文杰, 胡根生, 等. 基于TPH-YOLO的无人机图像麦穗计数方法[J]. 农业工程学报, 2023, 39(1): 155-161.
- [11] 白强, 高荣华, 赵春江, 等. 基于改进YOLOV5s网络的奶牛多尺度行为识别方法[J]. 农业工程学报, 2022, 38(12): 163-172.
- [12] 李朝. 基于无人机图像的草地鼠洞检测方法研究[D]. 呼和浩特: 内蒙古农业大学, 2023.
- [13] 杨婷. 基于无人机航拍图像的目标检测算法研究[D]. 西安: 西安工业大学, 2023.
- [14] 贾一凡, 曹天一, 白越. 基于Ghost改进的YOLOv5轻量化双目视觉无人机避障算法[J]. 液晶与显示, 2024, 39(1): 111-119.
- [15] 李尚平, 郑锐, 文春明, 等. 基于改进YOLO v5s的甘蔗切种茎节特征识别定位技术[J]. 农业机械学报, 2023, 54(10): 234-245+293.