

基于深度学习的 CNN 手写体数字识别

李 伟¹, 孙云娟²

(1.河南师范大学 电子与电气工程学院, 河南 新乡 453007; 2.河南师范大学 新联学院, 河南 新乡 453007)

摘 要:从深度学习卷积神经网络 (CNN) 的结构功能出发, 重点研究了手写体数字通过神经网络的识别性能, 以及当手写体数字染有各种噪声 (高斯噪声、椒盐噪声、泊松噪声和斑点噪声等) 时的性能。为了改善和提高卷积神经网络的性能, 采用迁移学习技术, 将 ReLu 学习单元更换为 LeakyReLu 学习单元, 其他层保持不变, 其目的是为了进一步改善 Sigmoid 神经元函数易饱和的缺点, 提高了学习效率和速度。

关键词: CNN; 深度学习; 手写体数字识别

DOI: 10.3969/j.issn.1674-5043.2024.01.010

中图分类号: TP319

文献标识码: A

文章编号: 1674-5043(2024)01-0056-05

计算机视觉是人工智能和计算机科学的子领域, 利用计算机开发真实世界的视觉感知, 由输入图像通过自动特征提取、分析、信息理解获得。在卷积神经网络 (CNN) 出现之前, 用于分类的任一分类算法都由手工设计的特征提取算子, 卷积神经网络出现之后, 转变为自动生成的特征提取算子。卷积神经网络得益于计算能力和训练数据的增加, 打破了传统的人工神经网络 (ANN) 的局限。近年来, 手写体数字识别吸引了许多研究者的兴趣, 在许多领域得到了应用^[1-2], 如: 邮政编码自动分拣、银行支票自动处理、车牌照识别等。由于存在书写格式以及笔画的变化, 印刷体数字识别相对简单一些。本文从深度学习的卷积神经网络的结构功能出发, 重点研究了手写体数字通过神经网络的识别性能, 以及当手写体数字染有各种噪声 (高斯噪声、椒盐噪声、泊松噪声和斑点噪声等) 时的性能。

1 理论基础

1.1 ANN

ANN 典型结构由多层感知器 MLP 构成, 训练算法是反向传播算法 (BP 算法)。为了避免 BP 网络收敛速度慢和局部极小值的缺点, 采用 RBF 径向基神经网络, 提高收敛速度和分类能力。径向基神经网络是典型的两层网络, 稳定性好。SVM 支持向量机神经网络对于典型线性和非线性两类判别问题具有很强的识别能力, 并且具有很好的泛化能力。

1.2 CNN

CNN 是一种常见的深度学习架构, 受生物自然视觉认知机制启发而来, 是一种特殊的多层前馈神经网络, 采用 BP 算法进行训练。CNN 和多层感知器 MLP 相似, 是多个连接层的堆栈, 每一层的输出是下一层的输入, 并且在网络训练学习过程中权值和偏置都要不断改变。在 CNN 中每一层称为特征映射, 利用图像局部卷积运算获得不同的特征。通常 CNN 有两部分构成: 特征提取和分类。特征提取主要进行 3 种运算: 卷积、非线性运算和下采样。卷积层和池化层交互地堆栈在一起产生特征映射, 在卷积层卷积运算之后进行修正线性激活函数 (ReLU) 操作, 提取特征映射的最高层用于分类。CNN 的基本结构图如图 1 所示。

(1) 卷积层: 卷积层的目的是提取输入的不同特征, 第一层卷积层只能提取一些基本的特征, 如边缘、线条和角等, 不同卷积核可以提取不同的特征, 在深层卷积神经网络中, 通过卷积操作可以提取图像低级到复杂的特征, 卷积层的局部连接和权重共享使需要学习的参数大大减小, 有利于训练较大卷积神经网络^[3]。在这一层图像的局部区域与可学习的权系数卷积运算后产生特征映射。每一卷积层存在多个特征映射, 同一特征映射共享加权系数。数学上, 第 l 卷积层输出特征映射。

收稿日期: 2023-07-20

作者简介: 李 伟 (1967-), 男, 河南新乡人, 硕士, 讲师, 主要从事数字图像处理、模式识别和水印技术方面的研究。E-mail: 13523254596@ 139.com




图1 卷积神经网络 CNN 的基本结构

$$o_{ij}^{(l)} = f^{(l)} \left(\sum_{m=1}^k \sum_{n=1}^k w_{m,n}^{(l)} \cdot o_{i+m,j+n}^{(l-1)} + b^{(l)} \right)$$

式中: $w_{m,n}^{(l)}$ 为第 l 层大小为 $k \times k$ 的卷积核; $o_{i+m,j+n}^{(l-1)}$ 为前一层 (第 $l-1$ 层) 的特征映射输出, 作为第 l 层的输入; $b^{(l)}$ 为偏置; 运算符 “ $\cdot$ ” 代表整个特征映射的卷积运算; $f^{(l)}$ 表示修正的线性激活函数 (ReLU), 将来自节点的加权输入求和并进行变换转换成该节点的输出。

(2) 池化层: 池化层是一种形式的下采样, 主要作用是通过减少网络的参数来减小计算量, 减少了网络的复杂性和学习时间, 并且能够在一定程度上控制过度拟合。通常在卷积层的后面会加上一个池化层, 下采样并不改变特征映射的数目。有多种形式的池化函数, 如: 最大值池化和平均值池化。第 p 池化层处的特征映射输出 $F^{(p)}$ 由前一层的特征映射 $f^{(p-1)}$ 获得:

$$F_{ij}^{(p)} = \max(f_{1+k(i-1), 1+k(j-1)}^{(p-1)}, \dots, f_{ki, 1+k(j-1)}^{(p-1)}, \dots, f_{1+k(i-1), kj}^{(p-1)}, \dots, f_{ki, kj}^{(p-1)})$$

式中: $k \times k$ 为模板大小, 且 $i \geq 1, j \leq (m-n+1)/k$; m 为输入特征映射的大小; n 为滤波器大小; $\max$ 为最大值池化, 有助于网络提取高阶特征。

(3) 分类层: 分类层是 CNN 的最后一层, 即最高层, 通常由全连接层和分类层构成。在 CNN 的最高层面, 提取高阶特征, 馈接到分类器的输入端。通常 CNN 具有一个或多个全连接层, 将特征向量形成一维向量, 作为输入预测所对应的目标类型。如果将输出值归一化在区间 (0, 1) 内来表示某一类型的出现概率, 这种模型称为 CNN-softmax。通常利用 SVM 分类器代替 softmax, 这种模型称为 CNN-SVM, 这种分类器是简单的逻辑回归, 将提取的高阶特征利用 SVM 进行分类。SVM 对于学习特征提供好的分类性能, 它不像其他神经网络存在局部最小值的问题, 并且 SVM 泛化性能好, 避免了过度拟合问题。

1.3 损失函数

神经网络的精度取决于损失函数的选择。通常选择交叉熵函数来训练模型^[4]。已知训练图像集包含 T 幅图像以及它们响应的输出类型, 经过模型训练得到学习函数 $\hat{f}(I; \theta)$, 它预测了输入图像 I 所对应的图像类型, 其中 θ 表示模型参数。

1.4 数据扩展

数据扩展^[5]的基本思想是利用随机图像变换同步增加训练数据的数量。要学习的网络可得到的数据越多, 该网络就越有效。数据扩展的目的是对于输入数据不同的变换 (旋转和尺度) 使网络模型保持不变。旋转和尺度变换经常用于扩展图像的数据。旋转范围选择 $\pm 15^\circ$ 的旋转角度, 尺度变换做同样处理。

1.5 学习迁移

学习迁移是机器学习领域中非常重要的一项技术, 它将已训练好的网络简单修改后重新开发出新的任务模型。数学上, 对于源域 D_s 及其学习目标 L_s 、目标域 D_T 及其学习目标 L_T , 迁移学习可以定义为分类任务, 利用 D_s 和 L_s 中的信息在 D_T 中得到学习模型的一个预测函数 $\hat{f}(\cdot)$, 其中 $D_s \neq D_T, L_s \neq L_T$ 。 $\hat{f}(\cdot)$ 起初对于 D_s 进行训练, 后来对于 D_T 进行微调。CNN 中现有几种常用的分类网络, 如: Alexnet、VGG-16、ResNet-18、Googlenet 等, 都非常方便采用迁移学习技术。

2 手写体数字特征的提取

手写体数字有许多特征^[6-7], 第一种类型的特征是以识别为目的的, 称为基于区域的特征。在提取基

于区域的特征时,将图像划分成9个相等的区域,对于每一个区域,提取9个不同的特征,共计81个特征。这9个特征包括:水平线数、垂直线数、右对角线数、左对角线数、水平线归一化长度、垂直线归一化长度、右对角线归一化长度、左对角线归一化长度、归一化面积。

除此之外,还有4个特征:

(1) 欧拉数: $E=C-H$, 其中 C 为二进制图像的连接单元数, H 为图像孔的个数。

(2) 面积比: 文本像素与总图像像素之比。

(3) 曲率: 匹配整个二进制图像的最小可能椭圆。

(4) 扭曲长度: 该特征是根据二进制图像像素计算的。它度量了最长线段长度,大小20个。这个特征能够适应书写风格的变化,如慢写到快写的变化。

因此,对于每一个数字图像,可获得 $9 \times 9 + 3 + 20 = 104$ 个特征。

第二种类型的特征是更高级的手写体特征,用于数字识别。

(1) HOG 特征: 即有向梯度特征,它是有关目标结构或形状的特征,描述了图像所在区域的有向梯度。这种特征和边沿特征非常相似,它给出的是边沿方向的信息,它的计算是在均匀分布的空间格上进行的,通常设定为 8×8 。

(2) SIFT 特征: 即尺度不变特征,用于检测和描述图像的本地特征,并且对于图像的尺度和旋转是不变的。

(3) SURE 特征: 即加速鲁棒特征,它由 SIFT 特征所产生,但比 SIFT 特征速度快,在图像变换方面性能更稳健。

手写体的这些特征可以通过 CNN 提取之后寄存在 CNN 当中,这体现出 CNN 所具有的强大功能。

3 设计的卷积神经网络

卷积神经网络模型流程图^[8-9]主要由两个阶段构成: CNN 训练期和 CNN 测试期,如图2所示。本文所用到的卷积神经网络共12层。第一层为输入层,分辨率为 28×28 的手写体灰度数字图像;第二层为卷积层,提取输入层图像的低级特征,8个卷积核,滤波器尺寸为 3×3 ;第三层为批处理归一化层,将上一层的输出信息批量归一化处理再送到下一层,目的是在训练过程中使每一层神经网络的输入保持相同的分布,以便在训练时提升模型的收敛速度;第四层为修正的线性单元函数 ReLu,是一个典型的非线性激活函数,克服了 Sigmoid 函数易饱和的弱点,提高了神经网络的学习效率和速度;第五层为池化层,采用最大值池化,池化区域大小为 2×2 ;第六层为卷积层,提取输入图像的高级特征,16个卷积核,滤波器尺寸为 3×3 ;第七层、第八层、第九层依次为批处理归一化层、修正的线性单元函数和池化层;第十层为全连接层,全连接层输出个数为10,代表10种类型输出,和普通的神经网络连接一样,该层具有10个输出神经单元;第十一层为 softmax 层,将全连接层的输出归一化,得出全连接层每一个输出的概率;第十二层为输出层,根据概率大小确定最后的输出类型。设计的卷积神经网络 CNN 的结构示意图如图3所示,设计的卷积神经网络 CNN 的正确链接示意图如图4所示。




图2 CNN模型流程图




图3 设计的卷积神经网络CNN的结构图




图 4 设计的卷积神经网络 CNN 的正确链接图

4 实验仿真和性能分析

利用 Matlab 语言环境进行基本的图像仿真^[10-11]。仿真环境: Matlab2019a, 采用 core i5 CPU 计算机, 1.60 GHz 4 G 内存 64 位操作系统。采用的数据集为标准的手写体数字数据集 MNIST 共 10 类, 10 000 幅, 分成训练集 (7 500 幅) 和测试集 (2 500 幅)。数据集中任选的 20 幅图像如图 5 所示。对于所设计的卷积神经网络模型, 在训练期间 CNN 从训练集中提取图像特征, 并且利用这些特征来训练模型。训练好的模型最终通过测试集进行测试, 为使训练好的模型性能更优越, 常常采用数据扩展技术。




图 5 MNIST 集中任选 20 幅手写体数字图像

CNN 的数学算法是 BP 神经网络算法, 加权系数和偏置的改变采用随机梯度下降算法 (SGD), 选择正交熵为损失函数。在训练 CNN 时, 学习率初值设为 0.01, 最大轮回数为 4, 测试频率 30, 归一化大小缺省设置。卷积神经网络的训练和测试示意图如图 6 所示, 测试精度为 96.36%, 损失值为 0.145 1。如果输入手写体数字图像染有高斯噪声, 测试精度大大下降, 高斯噪声方差 0.01, 测试平均精度为 74.32%; 高斯噪声方差 0.02, 测试精度为 71.8%; 高斯噪声方差为 0.03, 测试精度 69.4%。如果输入手写体数字图像染有椒盐噪声, 测试精度下降, 椒盐密度为 0.005, 测试精度为 88.68%; 椒盐密度为 0.01, 测试精度为 81.32%; 椒盐密度为 0.02, 测试精度为 69.68%。如果输入手写体图像染有斑点噪声, 测试精度为 93.24%, 和无噪声时相比测试精度略有下降。如果输入手写体数字图像染有泊松噪声时, 测试精度不变。

为了改善设计的卷积神经网络的抗噪声性能, 采用迁移学习技术, 将 CNN 中的 ReLu 学习单元换成 LeakyReLu 学习单元, 其他层保持不变, 目的是为了进一步改善神经元函数易饱和的缺点, 提高学习效率和速度。经过训练后测试精度为 96.44%, 损失为 0.1436, 精度基本保持不变。如果输入手写体数字图像染有

高斯噪声, 高斯噪声方差 0.01, 测试精度为 76.92%; 高斯噪声方差 0.02, 测试精度为 73.84%; 方差高斯噪声为 0.03, 测试精度 70.6%。如果输入手写体图像染有椒盐噪声, 测试精度下降, 椒盐密度为 0.005; 测试精度为 92.04%; 椒盐密度为 0.01, 测试精度 86.72%; 椒盐密度为 0.02, 测试精度为 77.32%。如果输入手写体图像染有斑点噪声, 测试精度为 93.72%。如果输入手写体图像染有泊松噪声时, 测试精度不变。通过实验仿真可知, 将 CNN 中的 ReLu 学习单元换成 LeakyReLu 学习单元后, 抗噪声性能得到了改善。抗高斯噪声性能改善幅度不太大, 抗椒盐噪声性能改善幅度比较大, 抗斑点噪声和泊松噪声性能最好。




图 6 设计卷积神经网络 CNN 的训练、测试示意图

5 结 语

本文重点研究了手写体数字通过卷积神经网络的识别性能, 为了改善和提高手写体数字识别卷积神经网络的性能, 采用迁移学习技术, 将 ReLu 学习单元更换为 LeakyReLu 学习单元, 提高了学习效率和速度。

参考文献:

- [1] JONATHAN J, MAURO C, ALEC P. Analysis of the proficiency of fully connected neural networks in the process of classifying digital images[J]. Expert Systems with Applications, 2019, 135(11): 12-38.
- [2] DECPIKA G, SOUMEN B. CNN-based multilingual handwritten numeral recognition: A fusion-free approach[J]. Expert Systems with Applications, 2021, 165(3): 113-124.
- [3] PAOLETTI M E, HAUT J M, PLAZA J, et al. A new deep convolutional neural network for fast hyperspectral image classification[J]. ISPRS Journal of photogrammetry and remote sensing, 2018, 145(11): 120-147.
- [4] SHAN G, BAO Z. New image denoising algorithm via improved deep convolutional neural network with perceptual loss[J]. Expert Systems with Applications, 2019, 138(12): 112-115.
- [5] HAN D, LIU Q, FAN W. A new image classification method using CNN transfer learning and web data augmentation[J]. Expert Systems with Applications, 2018, 95(4): 43-56.
- [6] CARLOS A, ANDRE L D, FABIO H A, et al. Deep learning for biological image classification[J]. Expert Systems with Applications, 2017, 85(11): 114-122.
- [7] RADHESYAM V, PRABUKUMAR M. Hyperspectral image classification using CNN with spectral and spatial features integration[J]. Infrared physics & Technology, 2020, 10(7): 103-106.
- [8] 涌井良幸, 涌井贞美. 深度学习的数学[M]. 杨瑞龙, 译. 北京: 人民邮电出版社, 2019: 116-125.
- [9] 李玉鑑, 张婷, 单传辉, 刘兆英. 深度学习卷积神经网络从入门到精通[M]. 北京: 机械工业出版社, 2019: 86-87.
- [10] 赵小川, 和灏. 深度学习理论及实践[M]. 北京: 清华大学出版社, 2021: 225-228.
- [11] 赵小川. 深度学习经典案例解析[M]. 北京: 机械工业出版社, 2021: 108-110.

(下转第 66 页)

参考文献:

- [1] 石智军,姚克,田宏亮,等.煤矿井下随钻测量定向钻进技术与装备现状及展望[J].煤炭科学技术,2019,47(5):22-28.
- [2] 李泉新,姚克,方俊,等.煤矿井下瓦斯高效精准抽采定向钻进技术与装备[J].煤炭科学技术,2023,51(增刊1):65-72.
- [3] 石智军,李泉新,姚克.煤矿井下智能化定向钻探发展路径与关键技术分析[J].煤炭学报,2020,45(6):2217-2224.
- [4] 王家豪,董浩斌,石智军,等.煤矿井下随钻测量电磁传输信道建模[J].煤炭学报,2015,40(7):1705-1710.
- [5] 李泉新,褚志伟.矿用泥浆脉冲无线随钻测量信号发生装置设计[J].工矿自动化,2019,45(8):32-37.
- [6] 郭爱军,汪凯斌,李雄伟.矿用电磁波随钻测量仪的研制及其应用[J].电子设计工程,2022,30(5):76-79,84.
- [7] 吴仲华,孙浩玉,张世平,等.电磁感应式随钻数据传输系统的研究[J].石油机械,2009,37(7):58-60,96.
- [8] 陈泽平,闫保永,王国震,等.煤矿井下随钻测量技术研究现状及展望[J].矿业安全与环保,2022,49(6):130-134.
- [9] 张林,陈容松.基于FSK无线通信的随钻测井系统设计[J].单片机与嵌入式系统应用,2011,11(12):65-68.
- [10] 朱海宽.无线随钻系统短节数据传输技术研究[D].成都:成都理工大学,2013:17-22.
- [11] 邱关源.电路[M].北京:高等教育出版社,2006:281-285.

Design of Magnetic Coupling Downhole Data Transmission System While Drilling

YANG Zhiqiang, ZHENG Xiaoliang*

(School of Electrical and Information Engineering, Anhui University of Science and Technology, Huainan 232001, China)

Abstract: Aiming at the problems of low drilling efficiency and deviation of drill pipe from the predetermined trajectory caused by the inability to grasp the trajectory of drill pipe in real time during the operation of ordinary drilling rigs in underground coal mines, a magnetic coupling data transmission system while drilling suitable for underground coal mines is designed to obtain information such as the trajectory of drill pipe in real time. The system includes signal modulation and demodulation module, relay module and mutual inductance coil. The modulation and demodulation circuit are designed by using the principle of binary frequency shift keying (2FSK). According to the principle of mutual inductance of electromagnetic coil and the analysis of circuit model, the resonant frequency of transmission system is set. When the resonant frequency of the transmission system is set at the center of the two modulation frequencies, the data transmission is more stable and reliable, which meets the needs of long-distance data transmission while drilling.

Keywords: underground coal mine; transmission while drilling; system design; modulation and demodulation; mutual inductance coil

(责任编辑:翟智卫)

(上接第 60 页)

Handwritten Digit Recognition Based on the Deep Learning of CNN

LI Wei¹, SUN Yunjuan²

(1. College, Electronic and Electrical Engineering, Henan Normal University, Xinxiang 453007, China;

2. Xinlian College of Henan Normal University, Xinxiang 453007, China)

Abstract: Beginning with the structure and function of deep learning of CNN, the recognition properties of the handcraft script digits are chiefly investigated through CNN, and the recognition properties of the handcraft script digits coupled with noise (such as Gaussian, salt & pepper, poisson, speckle etc.). The technology of learning transfer is adopted to improve the properties of the designed CNN, replacing the learning unit ReLu with LeakyReLu, the other layers unchanged. It improves the defect that the sigmoid function is easily saturated, and the learning efficiency.

keywords: CNN; deep learning; handwritten digit recognition

(责任编辑:翟智卫)